考点2: 数据清洗

一.考试重点:

1. NaN布尔索引陷阱(90%考生会错!)
2. 中位数填充缺失值
3. 生成清洗规范审核报告

数据清洗（Data Cleaning）是数据预处理中的关键步骤，旨在识别并修正或删除数据集中不准确、不完 整、格式错误或无关的数据，从而提高数据质量，为后续分析、建模等任务打下良好基础。

二、(考点)Python 中常用的数据清洗模块及函数

1. pandas : 核心库，用于结构化数据（如表格）的处理。

常用函数(考点)： pd.read_csv() 读取csv文件中数据 df.isnull() / df.isna()： 检测缺失值 df.dropna()： 删除含缺失值的行/列 df.fillna()： 填充缺失值

df.median()： 计算中位数

df.mean() :计算平均值

df.std() :计算标准差

df.var() :计算方差

df.sum()：求和

df.to_csv('cleaned_data.csv', index=False, encoding='utf-8'):保存数据到csv文件(考试可能要求)

df = pd.read_excel("excel文件.xlsx", sheet_name="表名", engine="openpyxl"):保存数据到excel

df.to_excel("excel文件.xlsx", sheet_name="表名", **engine="openpyxl"**, index=False):保存数据到excel文件

注意:如果考试要求保存的excel文件后缀名是.xlsx,一定要加**engine="openpyxl"**.

df.drop()： 删除指定行或列 df.loc[] / df.query()： 条件筛选

df.dtypes： 查看数据类型

2. numpy : 提供数值计算支持，常配合 pandas 使用。

如： np.nan 表示缺失值

三.案例

1.案例一:

```python
#导入pandas库，用处处理表格数据，并给它取了个别名pd
import pandas as pd
#导入numpy库，用于缺失值处理，并给它取了个别名np
import numpy as np

#定义数据清洗的函数
def data_cleaning_example():
    """
    考试标准题型：学生成绩表清洗
    要求：
    1. 成绩缺失的用中位数填充
    2. 剔除"艺术"学院学生
    3. 保留学院信息为空(NaN)的学生 ← 这是陷阱!
    """
    #输出提示语
    print("=" * 70)
    print("数据清洗示例 - 学生成绩表")
    print("=" * 70)

    # 步骤1: 构造原始数据(考试会给CSV文件,需要用pd.read_csv读取,代码data=pd.read_csv(xx.csv))
    """
    #定义原始数据，用dict字典类型存
    data = {
    '姓名': ['张三', '李四', '王五', '赵六', '钱七', '孙八'],
    '成绩': [85, np.nan, 90, 78, 88, 92],
    '学院': ['计算机', '艺术', '数学', '物理', np.nan, '艺术']
    }
    #数据类型转换：将dict字典类型数据转换为pandas表格类型数据
    df = pd.DataFrame(data)
    """
    #
    #读取csv数据，存储为pandas表格类型数据
    df = pd.read_csv("学生成绩.csv", encoding='utf-8')

    #输出提示语
    print("\n【原始数据】")
    print(df)
    print(f"\n原始数据行数: {len(df)}")

    # 步骤2: 检查缺失值(加分项)
    print("\n【缺失值检查】")
    print(df.isnull().sum())

    # 步骤3: 用成绩中位数填充缺失值
    # 考点: median()会自动忽略NaN
    #调出表格中“成绩”这列数据并计算中位数，并存在变量中
    median_score = df['成绩'].median()
    #输出提示
    print(f"\n成绩中位数: {median_score}")
    #用中位数填充表格中成绩这列的空值
    df['成绩'] = df['成绩'].fillna(median_score)
    #输出提示

    print("\n【填充缺失值后】")
```

```
    print(df)

    # 步骤4：剔除"艺术"学院,但保留学院为NaN的记录
    # 这是最重要的考点!
    print("\n" + "="*70)
    print("关键考点：NaN布尔索引陷阱")
    print("="*70)

    """
    #错误写法1（90%考生会这样写!）
    #打印信息,告诉下面的写法错误
    print("\n错误写法：df[df['学院'] != '艺术']")
    #错误写法
    df_wrong = df[df['学院'] != '艺术']
    print(df_wrong)
    print(f"结果：钱七(学院为NaN)被误删！剩余{len(df_wrong)}行")
    print("\n 原因分析:")
    print(" NaN != '艺术' 返回 NaN（不是True也不是False)")
    print(" 布尔索引会把NaN视为False,导致该行被过滤")
    """

    # 正确写法
    print("\n 正确写法：df[(df['学院'] != '艺术') | df['学院'].isna()]")
    #声明变量存剔除"艺术"学院,但保留学院为NaN的记录
    df_cleaned = df[(df['学院'] != '艺术') | df['学院'].isna()]
    #输出提示
    print(df_cleaned)
    print(f"结果：钱七(学院为NaN)被正确保留！剩余{len(df_cleaned)}行")
    print("\n" + "="*70)

    # 步骤5：最终验证
    #输出
    print("\n【清洗后数据验证】")
    print(f"艺术学院学生已剔除：{len(df[df['学院'] == '艺术'])} 条")
    print(f"学院为空学生已保留：{len(df_cleaned[df_cleaned['学院'].isna()])} 条")
    print(f"成绩列有缺失值：{df_cleaned['成绩'].isna().sum()} 条")
    #结束函数的同时 ，返回原表格数据，需要保留数据
    return df, df_cleaned

#定义生成清洗报告的函数，参数分别为：原表格数据，清洗后的数据
def generate_cleaning_report(df_original, df_cleaned):
    """
    生成数据清洗规范审核报告
    考点：报告格式必须按标准模板
    """
    #输出提示
    print("\n" + "="*70)
    print("数据清洗规范审核报告")
    print("="*70)
    #声明变量，存清洗报告
    report = f"""
        1. 数据表基本信息

        (1) 数据源文件所在路径：../资源包/student_data.csv
```

```
        (2) 用户数量:
        - 原始数据: {len(df_original)} 条
        - 清洗后数据: {len(df_cleaned)} 条
        (3) 用户特征:
        - 字段: 姓名(字符串)、成绩(数值型)、学院(字符串)
        - 成绩范围: [{df_cleaned['成绩'].min()}, {df_cleaned['成绩'].max()}]
        2. 清洗规范审核
        (1) 处理后的数据文件是否能正常打开: 是
        - 清洗后数据已成功保存,可通过pandas正常读取
        (2) 是否有未处理的缺失值: 否
        - "成绩"列: 原缺失值已用中位数({df_cleaned['成绩'].median()})填充
        - "学院"列: 保留{df_cleaned['学院'].isna().sum()}个空值(符合业务要求)
        (3) 是否有未处理的异常值:  否
        - 成绩范围在[0, 100]内,无异常值
        - "艺术"学院已按规则全部剔除
        3. 清洗是否合格(合格/不合格): 合格
        理由:
        - 缺失值按规则使用中位数填充(针对需保留的记录)
        - 指定无效类别("艺术"学院)已完全剔除
        - 允许保留的空学院记录正确留存
        - 最终数据结构完整、逻辑一致
        4. 清洗后存在问题的用户:
        | 姓名 | 问题描述 | 是否保留 | 备注 |
        |------|---------|---------|------|
        {df_cleaned[df_cleaned['学院'].isna()]['姓名'].values[0] if df_cleaned['学
院'].isna().any() else '无'} | 学院信息缺失(NaN) | ? 是 | 符合业务要求,允许保留 |
        说明: 其余用户数据完整、有效
        报告生成时间: 2025年12月4日
        审核人: 数据治理小组
        """
    #输出报告
    print(report)
    #结束函数同时，返回清洗报告
    return report

#定义主函数
def main():
    """主函数"""
    #调用数据清洗的函数，并将函数返回的2个结果存在2个变量中
    df_original, df_cleaned = data_cleaning_example()
    #调用生成清洗报告的函数，并将函数返回结果存在变量
    report = generate_cleaning_report(df_original, df_cleaned)
    #将清洗好的数据存在csv指定文件中
    df_cleaned.to_csv('cleaned_data.csv', index=False, encoding='utf-8')
    #提示
    print("\n清洗后数据已保存至: cleaned_data.csv")

#python程序入口
if __name__ == "__main__":
    #调用主函数
    main()
```

运行效果如下:

```
PS C:\Users\sxwork\Desktop\AItest> & D:\python3.8\python.exe c:/Users/sxwork/Desktop/AItest/数
据清洗1.py
======================================================================
数据清洗示例 - 学生成绩表
======================================================================

【原始数据】
   姓名    成绩   学院
0  张三  85.0  计算机
1  李四   NaN   艺术
2  王五  90.0   数学
3  赵六  78.0   物理
4  钱七  88.0  NaN
5  孙八  92.0   艺术

原始数据行数: 6
```

```
【缺失值检查】
姓名    0
成绩    1
学院    1
dtype: int64

成绩中位数: 88.0

【填充缺失值后】
   姓名    成绩   学院
0  张三  85.0  计算机
1  李四  88.0   艺术
2  王五  90.0   数学
3  赵六  78.0   物理
4  钱七  88.0  NaN
5  孙八  92.0   艺术

======================================================================
关键考点: NaN布尔索引陷阱
======================================================================
```

```
 正确写法: df[(df['学院'] != '艺术') | df['学院'].isna()]
   姓名    成绩   学院
0  张三  85.0  计算机
2  王五  90.0   数学
3  赵六  78.0   物理
4  钱七  88.0  NaN
结果: 钱七(学院为NaN)被正确保留! 剩余4行

======================================================================

【清洗后数据验证】
艺术学院学生已剔除: 2 条
学院为空学生已保留: 1 条
成绩列有缺失值: 0 条

======================================================================
数据清洗规范审核报告
======================================================================
```

```
1. 数据表基本信息
(1) 数据源文件所在路径: ../资源包/student_data.csv
(2) 用户数量:
- 原始数据: 6 条
- 清洗后数据: 4 条
(3) 用户特征:
- 字段: 姓名(字符串)、成绩(数值型)、学院(字符串)
- 成绩范围: [78.0, 90.0]
2. 清洗规范审核
(1) 处理后的数据文件是否能正常打开: 是
- 清洗后数据已成功保存,可通过pandas正常读取
(2) 是否有未处理的缺失值: 否
- "成绩"列: 原缺失值已用中位数(86.5)填充
- "学院"列: 保留1个空值(符合业务要求)
(3) 是否有未处理的异常值:  否
- 成绩范围在[0, 100]内,无异常值
- "艺术"学院已按规则全部剔除
3. 清洗是否合格(合格/不合格): 合格
```

```
理由:
- 缺失值按规则使用中位数填充(针对需保留的记录)
- 指定无效类别("艺术"学院)已完全剔除
- 允许保留的空学院记录正确留存
- 最终数据结构完整、逻辑一致
4. 清洗后存在问题的用户:
| 姓名 | 问题描述 | 是否保留 | 备注 |
|------|---------|---------|------|
钱七 | 学院信息缺失(NaN) | ? 是 | 符合业务要求,允许保留 |
说明: 其余用户数据完整、有效
报告生成时间: 2025年12月4日
审核人: 数据治理小组
```

2.案例二:原始表格包含三列：姓名、成绩、学院需完成以下清洗任务：

- [ ] 成绩缺失的学生成绩用“成绩列的中位数”填充；
- [ ] 剔除“艺术”学院的学生记录；
- [ ] 保留学院信息为空（即 NaN）的学生记录（即不能因学院为空而被删除）。 注意：第3点说明不能简单用 dropna(subset=['学院']) 删除空学院，而是要保留这些记录

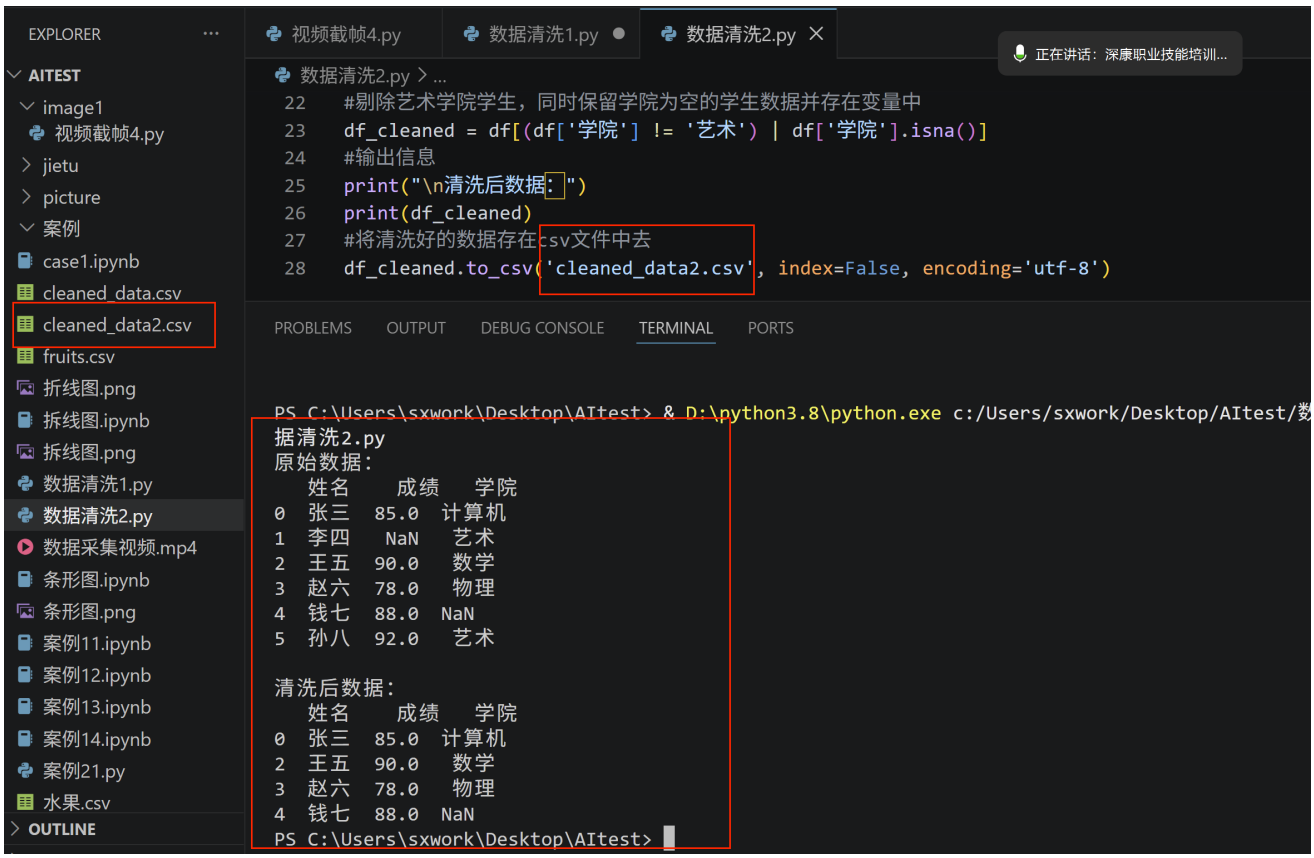
```
#导入pandas库用于处理表格数据，并取了个别名pd
import pandas as pd
#导入numpy库用例缺失值的表示，并取了个别名np
import numpy as np

# 原始数据
data = {
'姓名': ['张三', '李四', '王五', '赵六', '钱七', '孙八'],
'成绩': [85, np.nan, 90, 78, 88, 92],
'学院': ['计算机', '艺术', '数学', '物理', np.nan, '艺术']
}
```

```
#数据类型转换：将字典类型的data数据转换为pandas中表格数据
df = pd.DataFrame(data)
#输出提示
print("原始数据：")
print(df)

#调用表格中”成绩“这一列数据，计算它的中位数，然后存在变量中
median_score = df['成绩'].median()
#用中位数填充表格中成绩这列中的nan空值数据
df['成绩'] = df['成绩'].fillna(median_score)
#剔除艺术学院学生，同时保留学院为空的学生数据并存在变量中
df_cleaned = df[(df['学院'] != '艺术') | df['学院'].isna()]
#输出信息
print("\n清洗后数据：")
print(df_cleaned)
#将清洗好的数据存在csv文件中去
df_cleaned.to_csv('cleaned_data.csv', index=False, encoding='utf-8')
```

运行效果如下



3.案例三:

```
#导入pandas库用于处理表格数据，并取了个别名叫pd
import pandas as pd
#导入numpy库用于处理缺失值，并取了个别名叫np
import numpy as np

#定义数据清洗函数
```

```python
def data_cleaning_example():  # 修复：函数名拼写错误 clerning→cleaning，exampie→example
    #输出提示
    print("="*70)
    print("数据清洗示例-学生成绩表")
    print("="*70)

    #原始数据
    data = {
        '姓名': ['张三', '李四', '王五', '赵六', '钱七', '孙八'],
        '成绩': [85, np.nan, 90, 78, 88, 92],  # 修复：多余的逗号和括号
        '学院': ['计算机', '艺术', '数学', '物理', np.nan, '艺术']
    }

    #数据类型转换：将字典类型数据data转换为pandas中表格数据df
    df = pd.DataFrame(data)
    #将原始复制一份存在变量df_original中
    df_original = df.copy()  # 保存原始数据
    #输出提示
    print("\n[原始数据]")
    print(df)
    #len(表格变量)：获得表格中数据行数
    print(f"\n原始数据行数：{len(df)}")

    print("\n[缺失值检查]")
    #输出表格中总共空数据行数
    print(df.isna().sum())
    #获得成绩的中位数，并存在变量中
    median_score = df['成绩'].median()
    print(f"\n成绩中位数：{median_score}")
    #用中位数填充表格中成绩这列空值
    df['成绩'] = df['成绩'].fillna(median_score)
    #输出提示
    print("\n[填充缺失值后]")
    print(df)
    #输出提示
    print("\n" + "="*70)
    print("关键考点：NaN布尔索引陷阱")
    print("="*70)
    # 剔除学院为空的行
    df_cleaned = df.dropna(subset=['学院'])
    #输出
    print("\n【清洗后数据验证】")
    print(f" 艺术学院学生数量：{len(df_cleaned[df_cleaned['学院'] == '艺术'])} 条")
    print(f" 学院为空学生已剔除：{len(df_original[df_original['学院'].isna()])} 条")
    print(f" 成绩列有缺失值：{df_cleaned['成绩'].isna().sum()} 条")
    #结束函数同时返回原数据，清洗后的数据
    return df_original, df_cleaned  # 修复：缩进（和函数内代码同层级）

#定义生成清洗报告的函数，参数分别为：原数据，清洗后的数据
def generate_cleaning_report(df_original, df_cleaned):
    # 修复：report内容缺失，补充报告逻辑
    #声明一个变量存报告信息

    report = f"""
```

```
                【数据清洗报告】
                1. 原始数据行数: {len(df_original)}
                2. 清洗后数据行数: {len(df_cleaned)}
                3. 缺失值填充: 成绩列填充中位数{df_original['成绩'].median()}
                4. 行剔除: 学院为空的行共{len(df_original[df_original['学院'].isna()])}条
                """
    #输出提示
    print("\n" + "="*70)
    print("数据清洗规范审核报告")
    print("="*70)
    #输出报告信息
    print(report)
    #结束函数同时返回报告信息
    return report

#主函数
def main():
    """主函数"""
    #调用数据清洗函数，并将函数的返回结果存2个变量
    df_original, df_cleaned = data_cleaning_example()
    #调用生成数据清洗函数，并将函数的返回结果存在变量
    report = generate_cleaning_report(df_original, df_cleaned)
    #将清洗后的数据存在csv文件中
    df_cleaned.to_csv('cleaned_data.csv', index=False, encoding='utf-8')
    #输出提示
    print("\n清洗后数据已保存至: cleaned_data.csv")

#python程序入口
if __name__ == "__main__":
    #调用主函数
    main()
```

运行效果如下:

```
PS C:\Users\sxwork\Desktop\AItest> & D:\python3.8\python.exe c:/Users/sxwork/Desktop/AItest/数
据清洗3.py
======================================================================
数据清洗示例-学生成绩表
======================================================================

[原始数据]
   姓名    成绩   学院
0  张三  85.0  计算机
1  李四   NaN   艺术
2  王五  90.0   数学
3  赵六  78.0   物理
4  钱七  88.0  NaN
5  孙八  92.0   艺术

原始数据行数: 6

[缺失值检查]
姓名    0
成绩    1
```

```
学院    1
dtype: int64

成绩中位数：88.0

[填充缺失值后]
   姓名    成绩   学院
0  张三  85.0  计算机
1  李四  88.0   艺术
2  王五  90.0   数学
3  赵六  78.0   物理
4  钱七  88.0  NaN
5  孙八  92.0   艺术

======================================================================
关键考点：NaN布尔索引陷阱
======================================================================
```

```
【清洗后数据验证】
艺术学院学生数量：2 条
学院为空学生已剔除：1 条
成绩列有缺失值：0 条

==========================================================================
数据清洗规范审核报告
==========================================================================

                【数据清洗报告】
               1. 原始数据行数：6
               2. 清洗后数据行数：5
               3. 缺失值填充：成绩列填充中位数88.0
               4. 行剔除：学院为空的行共1条


清洗后数据已保存至：cleaned_data.csv
```

四.数据清洗模块（表格数据处理）操作流程（含题目要求 + 代码简析）

1.题目要求分析

该模块要对包含“姓名、成绩、学院”的表格数据进行清洗处理。具体任务包括：用中位数填充缺失的成绩；剔除“艺术”学院的学生；保留学院信息为空的学生。这需要我们能够处理表格数据，计算中位数，进行条件筛选等操作。

2.操作流程分析

1. **新建文件**：在 VS Code 中新建一个名为data_cleaning.py的文件，用于编写数据清洗的代码。
2. **复制代码并运行**：将提供的代码复制到文件中，由于数据已内置在代码中，无需修改代码即可直接运行，程序会自动完成数据清洗操作。

3.代码简析

导入pandas库（处理表格数据）和numpy库（处理缺失值）

import pandas as pd

import numpy as np

```
# 构造原始表格数据：字典格式，key是列名，value是对应列的所有数据
data = {
'姓名': ['张三', '李四', '王五', '赵六', '钱七', '孙八'],
'成绩': [85, np.nan, 90, 78, 88, 92], # np.nan表示成绩缺失
'学院': ['计算机', '艺术', '数学', '物理', np.nan, '艺术'] # np.nan表示学院为空
}
# 将字典转为pandas数据表（DataFrame），方便后续处理
df = pd.DataFrame(data)
# 打印原始数据，查看清洗前的状态
print("原始数据:")
print(df)
# 1. 用成绩列的中位数填充缺失值
# 计算成绩列的中位数（自动忽略缺失值np.nan），保存到median_score变量
median_score = df['成绩'].median()
# 用中位数填充成绩列的所有缺失值，inplace=True表示直接修改原数据表
df['成绩'] = df['成绩'].fillna(median_score)
# 2. 剔除“艺术”学院学生，同时保留学院为空的记录
# 条件1：学院列不等于“艺术”；条件2：学院列为空（isna()判断为空）
# 两个条件用“|”连接（表示“或”），满足任一条件就保留该行
df_cleaned = df[(df['学院'] != '艺术') | df['学院'].isna()]
# 打印清洗后的数据，查看结果
print("\n清洗后数据:")
print(df_cleaned)
```

- **导入库**：pandas用于处理表格数据，numpy用于处理缺失值。
- **构造数据**：使用字典data构造原始表格数据，包含“姓名”“成绩”“学院”三列，其中np.nan表示缺失值。
- **转换为　DataFrame**：将字典数据转换为pandas的DataFrame对象，方便进行数据处理。
- **填充缺失值**：计算“成绩”列的中位数，使用fillna方法用中位数填充缺失的成绩。
- **筛选数据**：通过条件筛选，剔除“艺术”学院的学生，同时保留学院信息为空的学生。
- **输出结果**：打印清洗前后的数据，方便查看处理效果。

五.考试要点总结(数据清洗):

1. 必背考点:

1. NaN布尔索引正确写法:
   df[(df['列'] != '值') | df['列'].isna()]
   或
   df[(df['列'] != '值') | df['列'].isnull()]
2. 中位数填充:
   df['列'].fillna(df['列'].median())
3. 检查缺失值:
   df.isnull().sum() 或 df.isna().sum()
4. 检查特定值:
   df[df['列'] == '值']
5. 读取CSV:
   df = pd.read_csv('file.csv', encoding='utf-8')

2.报告模板必备内容:

1. 数据源路径: ../资源包/xxx.csv
2. 用户数量: 原始X条, 清洗后Y条
3. 三个"是否":

- 能正常打开: 是
- 未处理缺失值: 否
- 未处理异常值: 否

4. 清洗是否合格: 合格
5. 存在问题的用户: 列出保留的NaN记录

3.易错点:

1. 忘记 | df['列'].isna() 导致NaN被删
2. 用固定值填充而非median()
3. 报告格式不规范
4. 忘记保存清洗后的CSV文件

- **变种题型:**

- 剔除多个类别: (df['列']!='值1') & (df['列']!='值2')
- 用平均值填充: fillna(df['列'].mean())
- 删除所有缺失值: df.dropna()
- 只删除特定列缺失: df.dropna(subset=['列名'])